

Profesor: Duván Cataño

Indicaciones generales

- El presente laboratorio debe desarrollarse en parejas utilizando el conjunto de datos seleccionado previamente (asociado a problemas de Regresión, Clasificación o Series de Tiempo).
- Todas las respuestas deben estar sustentadas con código reproducible (Python o R) y análisis estadístico riguroso contextualizado al dominio del problema.
- Redondear los resultados numéricos a cuatro cifras decimales.
- Para todas las pruebas de hipótesis, se debe especificar explícitamente: supuesto de la prueba, hipótesis H_0 y H_1 , *valor - p* obtenido, decisión estadística con $\alpha = 0,05$ y conclusión en el contexto del problema.

1. Contextualización del Conjunto de Datos y Definición Poblacional

- Defina la población objetivo, la muestra en estudio y la unidad de observación de su base de datos.
- Identifique la naturaleza analítica del dataset (Regresión, Clasificación o Series de Tiempo) y formule la variable respuesta (si aplica) junto con el objetivo del modelado posterior.
- Reporte el número total de observaciones, variables totalizadas y clasifique cada variable según su tipo (Cualitativa nominal/ordinal, Cuantitativa discreta/continua).
- Identifique la presencia de valores faltantes o inconsistencias operacionales en los datos.

2. Exploración Univariada y Medidas Estructurales Para al menos tres variables cuantitativas clave del conjunto de datos:

- Calcule e interprete las **Medidas de Tendencia Central**: Media, mediana y moda. Compare su comportamiento para identificar sesgos preliminares.
- Calcule e interprete las **Medidas de Dispersión**: Rango, varianza, desviación estándar y coeficiente de variación. Indique cuál variable presenta mayor variabilidad relativa.
- Calcule e interprete las **Medidas de Posición**: Cuartiles (Q_1, Q_2, Q_3) y percentiles clave (P_{10}, P_{90}).

3. Medidas de Forma y Representaciones Gráficas Univariadas Para las variables seleccionadas en el punto anterior:

- Determine el **Coefficiente de Asimetría** y la **Curtosis** (junto con el exceso de curtosis). Clasifique las distribuciones (Simétricas/Asimétricas; Leptocúrticas, Mesocúrticas o Platicúrticas).
- Construya visualizaciones apropiadas: Histogramas y Diagramas de Caja y Bigotes (Boxplots) para variables cuantitativas; Gráficos de barras para variables cualitativas.
- Mediante el criterio del Rango Inter cuartilico (IQR), detecte y justifique el impacto de los valores atípicos (*outliers*) en las medidas descriptivas calculadas.

4. Formulación de Hipótesis y Errores de Decisión

- Defina formalmente los conceptos de Hipótesis Nula (H_0), Hipótesis Alternativa (H_1), Error Tipo I (α) y Error Tipo II (β).
- Formule un escenario práctico basado en su conjunto de datos donde incurrir en un Error Tipo I sea más costoso que un Error Tipo II (o viceversa), justificando desde la analítica de negocios/proceso.

5. **Asociación y Dependencia entre Variables Continuas** Seleccione pares de variables cuantitativas continuas de su conjunto de datos:
- Construya diagramas de dispersión (*scatter plots*) e interprete visualmente la relación lineal o no lineal.
 - Calcule la Covarianza y el Coeficiente de Correlación de Pearson.
 - Evalúe las pruebas de correlación no paramétricas de *Spearman* y *Kendall*.
 - Compare los *p*–valores e índices de *Pearson vs. Spearman/Kendall*. Explique estadísticamente las diferencias encontradas cuando existen valores atípicos o no linealidades.
6. **Pruebas de Independencia para Variables Categóricas** Seleccione dos pares de variables cualitativas de su dataset:
- Construya las tablas de contingencia (frecuencias observadas y esperadas).
 - Realice la **Prueba de Independencia Chi-cuadrado** (χ^2). Concluya si existe dependencia estadísticamente significativa.
 - Calcule la **Información Mutua (Mutual Information)** como medida de dependencia no lineal/informacional entre las variables categóricas y compare el resultado con el test hipotético.
7. **Asociación entre Variables Mixtas (Cualitativa vs. Cuantitativa)** Seleccione una variable cualitativa (con 2 o más categorías) y una cuantitativa continua:
- Evalúe los supuestos de normalidad (por grupo) y homogeneidad de varianzas (homocedasticidad).
 - Aplique la prueba paramétrica **ANOVA** (Análisis de Varianza) para comparar las medias de los grupos.
 - Aplique la prueba no paramétrica equivalente de **Kruskal-Wallis**.
 - Compare las conclusiones de ambas pruebas y justifique cuál es la prueba estadísticamente más adecuada según el cumplimiento o violación de supuestos.
8. **Síntesis Analítica y Selección de Variables** Elabore una síntesis ejecutiva donde responda:
- ¿Qué variables muestran mayor capacidad de asociación con su variable objetivo o interés principal?
 - ¿Cómo influyó la presencia de asimetría y outliers en la elección entre pruebas paramétricas y no paramétricas?
 - ¿Qué variables recomienda descartar o transformar para las etapas posteriores de modelado distributivo o predictivo?
-