

Profesor: Duván Cataño

Indicaciones generales

- El presente laboratorio debe desarrollarse en parejas utilizando el conjunto de datos seleccionado previamente (asociado a problemas de Regresión, Clasificación o Series de Tiempo).
 - Todas las respuestas deben estar sustentadas con código reproducible (Python o R) y análisis estadístico riguroso contextualizado al dominio del problema.
 - Redondear los resultados numéricos a cuatro cifras decimales.
-

1. Contextualización del Conjunto de Datos y Definición Poblacional

- Defina la población objetivo, la muestra en estudio y la unidad de observación de su base de datos.
- Identifique la naturaleza analítica del dataset (Regresión, Clasificación o Series de Tiempo) y formule la variable respuesta (si aplica) junto con el objetivo del modelado posterior.
- Reporte el número total de observaciones, variables totalizadas y clasifique cada variable según su tipo (Cualitativa nominal/ordinal, Cuantitativa discreta/continua).
- Identifique la presencia de valores faltantes o inconsistencias operacionales en los datos.

2. Exploración Univariada y Medidas Estructurales Para al menos tres variables cuantitativas clave del conjunto de datos:

- Calcule e interprete las **Medidas de Tendencia Central**: Media, mediana y moda. Compare su comportamiento para identificar sesgos preliminares.
- Calcule e interprete las **Medidas de Dispersión**: Rango, varianza, desviación estándar y coeficiente de variación. Indique cuál variable presenta mayor variabilidad relativa.
- Calcule e interprete las **Medidas de Posición**: Cuartiles (Q_1, Q_2, Q_3) y percentiles clave (P_{10}, P_{90}).

3. Medidas de Forma y Representaciones Gráficas Univariadas Para las variables seleccionadas en el punto anterior:

- Determine el **Coefficiente de Asimetría** y la **Curtosis** (junto con el exceso de curtosis). Clasifique las distribuciones (Simétricas/Asimétricas; Leptocúrticas, Mesocúrticas o Platicúrticas).
- Construya visualizaciones apropiadas: Histogramas y Diagramas de Caja y Bigotes (Boxplots) para variables cuantitativas; Gráficos de barras para variables cualitativas.
- Mediante el criterio del Rango Intercuartílico (IQR), detecte y justifique el impacto de los valores atípicos (*outliers*) en las medidas descriptivas calculadas.

4. Asociación y Dependencia entre Variables Continuas Seleccione pares de variables cuantitativas continuas de su conjunto de datos:

- Construya diagramas de dispersión (*scatter plots*) e interprete visualmente la relación lineal o no lineal.
- Calcule la Covarianza y el Coeficiente de Correlación de Pearson.
- Evalúe las pruebas de correlación no paramétricas de *Spearman* y *Kendall*.
- Compare los p -valores e índices de *Pearson vs. Spearman/Kendall*. Explique estadísticamente las diferencias encontradas cuando existen valores atípicos o no linealidades.

5. **Pruebas de Independencia para Variables Categóricas** Seleccione dos pares de variables cualitativas de su dataset:

- Construya las tablas de contingencia (frecuencias observadas y esperadas).
- Realice la **Prueba de Independencia Chi-cuadrado** (χ^2). Concluya si existe dependencia estadísticamente significativa.
- Calcule la **Información Mutua (Mutual Information)** como medida de dependencia no lineal/informacional entre las variables categóricas y compare el resultado con el test hipotético.

6. **Asociación entre Variables Mixtas (Cualitativa vs. Cuantitativa)** Seleccione una variable cualitativa (con 2 o más categorías) y una cuantitativa continua:

- Evalúe los supuestos de normalidad (por grupo) y homogeneidad de varianzas (homocedasticidad).
- Aplique la prueba paramétrica **ANOVA** (Análisis de Varianza) para comparar las medias de los grupos.
- Aplique la prueba no paramétrica equivalente de **Kruskal-Wallis**.
- Compare las conclusiones de ambas pruebas y justifique cuál es la prueba estadísticamente más adecuada según el cumplimiento o violación de supuestos.

7. **Síntesis Analítica y Selección de Variables** Elabore una síntesis ejecutiva donde responda:

- ¿Qué variables muestran mayor capacidad de asociación con su variable objetivo o interés principal?
- ¿Cómo influyó la presencia de asimetría y outliers en la elección entre pruebas paramétricas y no paramétricas?
- ¿Qué variables recomienda descartar o transformar para las etapas posteriores de modelado distributivo o predictivo?

8. **Entregable**

- Proyecto completo en VSCode.
 - Notebooks de Análisis.
 - Aplicación funcional en Streamlit o Dashboard.
-